

Libro de códigos

- **Proyecto:** Obtención y Limpieza de Datos
- **Fuente:** Buscador de establecimientos educativos del Ministerio de Educación de Guatemala
- **Filtro:** NIVEL ESCOLAR: DIVERSIFICADO
- **Fecha de extracción documentada por el equipo:** 17 de julio de 2026
- **Fecha de cierre de calidad:** 31 de agosto de 2026
- **Versión del conjunto limpio:** 1.0.0

Integrantes

- Vianka Castro
- Angie Vela
- Nina Najera
- Ricardo Godínez

Todos los integrantes contribuyeron al repositorio y al libro de códigos. El CSV final contiene las 17 variables de la fuente y la variable derivada ZONA_CAPITAL.

Variables del conjunto limpio

Responsable	Variable	Descripción	Tipo	Dominio permitido	Valores posibles	Tratamiento aplicado
Vianka	CODIGO	Identificador oficial del establecimiento	Texto no anulable	NN-NN-NNNN-NN, único	11,867 códigos observados	Se conserva como texto y se validan formato, unicidad y consistencia geográfica.
Vianka	DISTRITO	Distrito educativo	Texto anulable	NN-NNN, NN-NN-NNNN o NA	Códigos completos observados y NA	Vacíos y 70 códigos incompletos NN- pasan a NA; el original queda en auditoría.
Vianka	DEPARTAMENTO	Departamento del establecimiento	Catagórico	22 departamentos oficiales	Guatemala, El Progreso, Sacatepéquez, Chimaltenango, Escuintla, Santa Rosa, Sololá, Totonicapán, Quetzaltenango, Suchitepéquez, Retalhuleu, San Marcos, Huehuetenango, Quiché, Baja Verapaz, Alta Verapaz, Petén, Izabal, Zacapa, Chiquimula, Jalapa y Jutiapa	Se normalizan tildes y CIUDAD CAPITAL se asigna a Guatemala.
Vianka	MUNICIPIO	Municipio del establecimiento	Catagórico	340 códigos municipales de SEGEPLAN	Valores de data/reference/municipios_guatemala.csv	Se determina por el prefijo municipal de CODIGO; la etiqueta MINEDUC se conserva cuando difiere legítimamente de la forma corta de SEGEPLAN.
Vianka	ZONA_CAPITAL	Zona de la Ciudad de Guatemala	Catagórico anulable	Zona 1 a Zona 25 o NA	22 zonas observadas; NA fuera de Ciudad Capital	Variable derivada de MUNICIPIO_ORIGINAL = ZONA N; preserva la sububicación al corregir el nivel municipal.
Ricardo	ESTABLECIMIENTO	Nombre del establecimiento	Texto anulable	Texto sin espacios iniciales, finales o múltiples	Texto libre o NA	Se normalizan espacios y se conserva la escritura visible. Las comparaciones de duplicados usan una clave separada.
Ricardo	DIRECCION	Dirección física	Texto anulable	Texto uniforme o NA	Texto libre o NA	Se reclasifican faltantes disfrazados, se retiran municipio y fechas redundantes, y se corrige 0 por Ø solo en contexto numérico.

Responsable	Variable	Descripción	Tipo	Dominio permitido	Valores posibles	Tratamiento aplicado
Ricardo	TELEFONO	Uno o varios teléfonos de contacto	Texto anulable	Uno o más números de 8 dígitos separados por ;	NNNNNNNN, listas con ; o NA	Se recuperan únicamente números de ocho dígitos; los componentes de siete dígitos no se completan y permanecen en TELEFONO_ORIGINAL.
Ricardo	SUPERVISOR	Nombre del supervisor	Texto anulable	Nombre sin espacios múltiples o NA	Texto libre o NA	Se corrigen grafías puntuales y variantes dentro del distrito. No se imputa sin fecha de vigencia.
Ricardo	DIRECTOR	Nombre del director	Texto anulable	Nombre sin título ni espacios múltiples o NA	Texto libre o NA	Se separa el título profesional, se normalizan variantes dentro del municipio y se conservan faltantes no imputables.
Nadissa	NIVEL	Nivel educativo usado como filtro	Catagórico	Una categoría	DIVERSIFICADO	Se conserva como metadato del filtro.
Nadissa	SECTOR	Sector del establecimiento	Catagórico	Cuatro categorías	PRIVADO, OFICIAL, COOPERATIVA, MUNICIPAL	Se fija un dominio cerrado.
Nadissa	AREA	Área geográfica	Catagórico anulable	Dos categorías o NA	URBANA, RURAL, NA	SIN ESPECIFICAR pasa a NA; los casos rurales de Ciudad Capital se conservan tras revisión.
Nadissa	STATUS	Estado administrativo	Catagórico	Cinco categorías	ABIERTA, CERRADA TEMPORALMENTE, CERRADA DEFINITIVAMENTE, TEMPORAL TITULOS, TEMPORAL NOMBRAMIENTO	Los estados temporales se conservan como categorías distintas.
Nadissa	MODALIDAD	Modalidad educativa	Catagórico	Dos categorías	MONOLINGUE, BILINGUE	Se fija un dominio cerrado.
Nadissa	JORNADA	Jornada de atención	Catagórico	Seis categorías	DOBLE, VESPERTINA, MATUTINA, SIN JORNADA, NOCTURNA, INTERMEDIA	SIN JORNADA se conserva para ofertas sin horario fijo.
Nadissa	PLAN	Plan educativo	Catagórico	Trece categorías	DIARIO(REGULAR), FIN DE SEMANA, SEMIPRESENCIAL (FIN DE SEMANA), SEMIPRESENCIAL (UN DÍA A LA SEMANA), A DISTANCIA, SEMIPRESENCIAL, VIRTUAL A DISTANCIA, SEMIPRESENCIAL (DOS DÍAS A LA SEMANA), SABATINO, DOMINICAL, MIXTO, IRREGULAR, INTERCALADO	Se preserva la categoría genérica semipresencial, sus variantes específicas y las categorías válidas de baja frecuencia.
Vianka	DEPARTAMENTAL	Dirección departamental educativa	Catagórico	26 categorías administrativas	Alta Verapaz, Baja Verapaz, Chimaltenango, Chiquimula, El Progreso, Escuintla, Guatemala Norte, Guatemala Occidente, Guatemala Oriente, Guatemala Sur, Huehuetenango, Izabal, Jalapa, Jutiapa, Petén, Quetzaltenango, Quiché, Quiché Norte, Retalhuleu, Sacatepéquez, San Marcos, Santa Rosa, Sololá, Suchitepéquez, Totonicapán y Zacapa	Se normaliza con un catálogo administrativo independiente del departamento geográfico.

Variable derivada

ZONA_CAPITAL se creó porque los archivos de Ciudad Capital almacenaban una zona en MUNICIPIO. Se calcula extrayendo N de ZONA N, antes de reemplazar el municipio por Guatemala. Permite analizar la distribución dentro de la capital sin conservar un valor que no pertenece al dominio municipal.

Columnas de auditoría

Las siguientes columnas se producen durante la limpieza preliminar y se excluyen del CSV analítico final:

Grupo	Columnas	Uso
Trazabilidad	archivo_origen, fila_origen	Identifican el CSV y la fila de origen.
Copias originales	CODIGO_ORIGINAL, DISTRITO_ORIGINAL, DEPARTAMENTO_ORIGINAL, MUNICIPIO_ORIGINAL, DEPARTAMENTAL_ORIGINAL, ESTABLECIMIENTO_ORIGINAL, DIRECCION_ORIGINAL, TELEFONO_ORIGINAL, SUPERVISOR_ORIGINAL, DIRECTOR_ORIGINAL	Conservan el valor anterior a la transformación.
Geografía	CODIGO_FORMATO_VALIDO, CODIGO_DUPLICADO, DISTRITO_FORMATO, DISTRITO_INCOMPLETO, DISTRITO_CONVERTIDO_A_NA, DISTRITO_FORMATO_VALIDO, DISTRITO_REQUIERE_REVISION, DEPARTAMENTO_FUERA_CATALOGO, DEPARTAMENTO_ES_CIUADAD_CAPITAL, MUNICIPIO_ZONA_INVALIDA, MUNICIPIO_CORREGIDO_CATALOGO, MUNICIPIO_CODIGO_CATALOGO_VALIDO, DEPARTAMENTAL_FUERA_CATALOGO, CODIGO_DEPARTAMENTO_CONSISTENTE, PREFIJO_CODIGO_AMBIGUO	Validan formato, catálogo y consistencia entre campos.
Duplicados	ESTABLECIMIENTO_CLAVE, ESTABLECIMIENTO_GRUPO_DUPLICADO, ESTABLECIMIENTO_DUPLICADO_CONFIRMADO, DUPLICADO_EXACTO_VIANKA	Localizan candidatos sin eliminar registros automáticamente.
Texto y personas	TELEFONO_DESCARTO_7_DIGITOS, SUPERVISOR_IMPUTADO, DIRECTOR_TITULO	Documentan decisiones específicas de limpieza.

Esquema de carga

CSV no almacena tipos categóricos. Para recuperar el esquema documentado y validar el archivo persistido se utiliza:

```
from src.validacion import cargar_csv_limpio, validar_datos

df = cargar_csv_limpio()
validar_datos(df)
```

Historial

Versión	Fecha	Descripción
0.1	17 de julio de 2026	Estructura y descripciones iniciales.
0.2	26 de agosto de 2026	Limpieza automatizada y columnas de auditoría.
1.0.0	31 de agosto de 2026	Catálogo oficial, decisiones de duplicados, dominios finales y validación del CSV persistido.